Implementasi Principal Component Analysis (PCA) dalam Pra-Pemrosesan Data untuk Analisis Clustering

Muhammad Ilham Maulana[1)], Izam Rosiawan[2)], Muhammad Ade Sulistiansyah[3)].
Program Studi Sains Data, Telkom University Surabaya, Surabaya, Indonesia
[1]muhammadilhammaulana@student.telkomuniversity.ac.id, [2] izamrosiawan@student.telkomuniversity.ac.id, [3] muhammadade@student.telkomuniversity.ac.id

ARTICLE INFO

Article info:
Laporan Tugas BesarRevised 21
Mata Kuliah: Infrastruktur Dan Platform Sains Data,
Telkom University Surabaya
Disusun: Desember 2025

Keywords:
Principal Component Analysis (PCA)
Clustering
Reduksi Dimensi
Visualisasi Data

ABSTRACT

Clustering merupakan metode *unsupervised learning* yang sering digunakan untuk mengelompokkan data, namun kinerjanya dapat menurun pada data berdimensi tinggi dan saling berkorelasi. Penelitian ini menerapkan Principal Component Analysis (PCA) sebagai tahap pra-pemrosesan untuk mereduksi dimensi data sebelum dilakukan clustering. Data numerik yang digunakan terlebih dahulu melalui proses pembersihan dan standarisasi, kemudian ditransformasikan menggunakan PCA dengan mempertahankan variansi utama data. Hasil reduksi dimensi menunjukkan bahwa PCA mampu menyederhanakan struktur data dan mengurangi redundansi variabel, sehingga data lebih siap digunakan pada tahap clustering dan analisis lanjutan.

This is an open access article under the CC BY-SA license.

1. Pendahuluan

Clustering merupakan salah satu metode *unsupervised learning* yang banyak digunakan untuk mengidentifikasi pola dan struktur tersembunyi dalam data berdimensi tinggi. Dalam praktiknya, data dunia nyata sering kali memiliki jumlah variabel yang besar dan saling berkorelasi, sehingga dapat menurunkan kinerja algoritma clustering serta menyulitkan proses interpretasi hasil. Kondisi ini dikenal sebagai *curse of dimensionality*, di mana peningkatan dimensi data justru mengurangi efektivitas analisis.

Untuk mengatasi permasalahan tersebut, teknik reduksi dimensi sering diterapkan sebelum proses clustering. Salah satu metode yang paling umum digunakan adalah Principal Component Analysis (PCA). PCA berfungsi untuk mentransformasikan data berdimensi tinggi ke dalam ruang berdimensi lebih rendah dengan tetap mempertahankan sebagian besar informasi penting yang direpresentasikan melalui variansi data. Dengan demikian, PCA dapat mengurangi redundansi antar variabel serta meningkatkan efisiensi komputasi.

Penelitian ini bertujuan untuk menerapkan PCA sebagai tahap pra-pemrosesan sebelum dilakukan analisis clustering. Fokus utama penelitian adalah menganalisis karakteristik data melalui komponen utama serta mengevaluasi kontribusi PCA dalam menyederhanakan struktur data. Hasil dari tahap ini diharapkan dapat mendukung proses clustering yang lebih stabil dan mudah diinterpretasikan. Kontribusi penelitian ini terletak pada penyusunan alur analisis yang sistematis dalam mengombinasikan reduksi dimensi menggunakan PCA dengan metode clustering, sehingga dapat menjadi referensi bagi penelitian serupa dalam pengolahan data berdimensi tinggi.

-

2. Metode

Penelitian ini menggunakan pendekatan kuantitatif dengan metode analisis data berbasis *unsupervised learning* untuk mengidentifikasi pola dan struktur dalam data. Metodologi penelitian disusun secara sistematis dan diimplementasikan menggunakan bahasa pemrograman Python sesuai dengan kode program yang dikembangkan. Tahapan penelitian dirancang agar setiap proses saling terhubung dan menghasilkan data yang siap dianalisis pada tahap selanjutnya.

2.1 Pengumpulan Data

Dataset yang digunakan dalam penelitian ini merupakan data terstruktur yang terdiri dari sejumlah atribut numerik. Data dimuat ke dalam lingkungan pemrograman untuk dilakukan pemeriksaan awal, meliputi struktur data, tipe variabel, serta keberadaan nilai kosong (*missing values*). Atribut yang tidak relevan atau tidak sesuai dengan kebutuhan analisis tidak digunakan dalam penelitian ini. Dataset hasil seleksi selanjutnya digunakan sebagai dasar untuk proses analisis lebih lanjut.

2.2 Pra-pemrosesan Data

Tahap pra-pemrosesan data dilakukan untuk meningkatkan kualitas data sebelum dianalisis. Proses ini meliputi pembersihan data dari nilai kosong dan inkonsistensi yang dapat memengaruhi hasil analisis. Setelah data bersih, dilakukan proses standarisasi fitur agar setiap variabel memiliki skala yang sebanding. Standarisasi diperlukan karena metode reduksi dimensi dan clustering sensitif terhadap perbedaan skala antar variabel.

2.3 Reduksi Dimensi Menggunakan Principal Component Analysis (PCA)

Principal Component Analysis (PCA) digunakan sebagai metode reduksi dimensi untuk menyederhanakan struktur data berdimensi tinggi. PCA bekerja dengan mentransformasikan variabel asli menjadi sekumpulan komponen utama yang saling tidak berkorelasi dan diurutkan berdasarkan besarnya variansi yang dapat dijelaskan. Jumlah komponen utama ditentukan berdasarkan nilai *explained variance ratio*, sehingga hanya komponen yang mampu merepresentasikan sebagian besar variansi data yang dipertahankan. Data hasil transformasi PCA digunakan sebagai representasi baru dalam ruang berdimensi lebih rendah.

2.4 K-Means Clustering

Algoritma K-Means Clustering digunakan untuk mengelompokkan data ke dalam beberapa kluster berdasarkan tingkat kemiripan antar data. Algoritma ini bekerja dengan menentukan sejumlah pusat kluster (*centroid*) dan mengelompokkan data berdasarkan jarak terdekat ke centroid tersebut. K-Means dipilih karena efisiensinya dalam menangani dataset berukuran besar, kemampuannya dalam membentuk kluster dengan struktur yang jelas, serta kemudahan interpretasi hasil melalui posisi centroid. Implementasi algoritma K-Means dilakukan menggunakan library *scikit-learn* versi 1.6.1 pada bahasa pemrograman Python.

3. Data Collection

Dataset yang digunakan dalam penelitian ini diperoleh dari sumber data terstruktur yang terdiri dari beberapa atribut numerik. Data dimuat ke dalam lingkungan pemrograman menggunakan library pengolahan data, kemudian ditampilkan sebagian untuk memahami struktur dan karakteristik awal dataset. Pada tahap ini, dilakukan pemeriksaan terhadap tipe data setiap atribut serta keberadaan nilai kosong (*missing values*). Atribut yang tidak relevan atau tidak bersifat numerik tidak digunakan dalam penelitian ini. Dataset yang telah dipilih selanjutnya digunakan sebagai data utama dalam proses analisis. Data kemudian dipisahkan menjadi kumpulan fitur tanpa label, mengingat penelitian ini

-

menggunakan pendekatan *unsupervised learning*. Dataset hasil seleksi ini menjadi dasar untuk tahap pra-pemrosesan dan reduksi dimensi.

4. Hasil Dan Diskusi

4.1 Hasil PCA

Tahap Principal Component Analysis (PCA) dilakukan untuk mereduksi jumlah variabel pada dataset obesitas agar analisis menjadi lebih sederhana tanpa kehilangan informasi penting. PCA bekerja dengan cara mengubah variabel-variabel asli menjadi sejumlah komponen baru yang tidak saling berkorelasi (principal components).

Berdasarkan hasil yang diperoleh, data memiliki dimensi sebesar (2087, 12) yang berarti terdapat 2087 baris data (responden/individu) dengan 12 komponen utama (PC1–PC12) hasil transformasi PCA. Tabel berikut menampilkan dua data teratas dari dataset sebagai contoh untuk menggambarkan struktur dan atribut yang digunakan dalam penelitian ini.:

PC1	PC2	PC3	PC4	PC5	PC6
-1.988	0.074	0.099	-0.606	1.036	-0.296
-2.621	-0.906	-0.809	5.564	-0.944	-5.742

PC7	PC8	PC9	PC10	PC11	PC12
0.765	0.162	-2.626	-0.368	-0.959	-0.983
2.199	1.677	-1.305	-1.800	0.433	1.969

Hasil reduksi dimensi ini menunjukkan bahwa struktur variasi utama data tetap terjaga meskipun jumlah fitur berkurang. Selanjutnya, data hasil PCA digunakan sebagai input untuk proses klasterisasi menggunakan K-Means.

Selain meningkatkan efisiensi komputasi, PCA juga memudahkan visualisasi pola data pada ruang dua dimensi (PC1 dan PC2), sehingga pemisahan klaster dapat diamati secara visual (lihat Gambar 4).

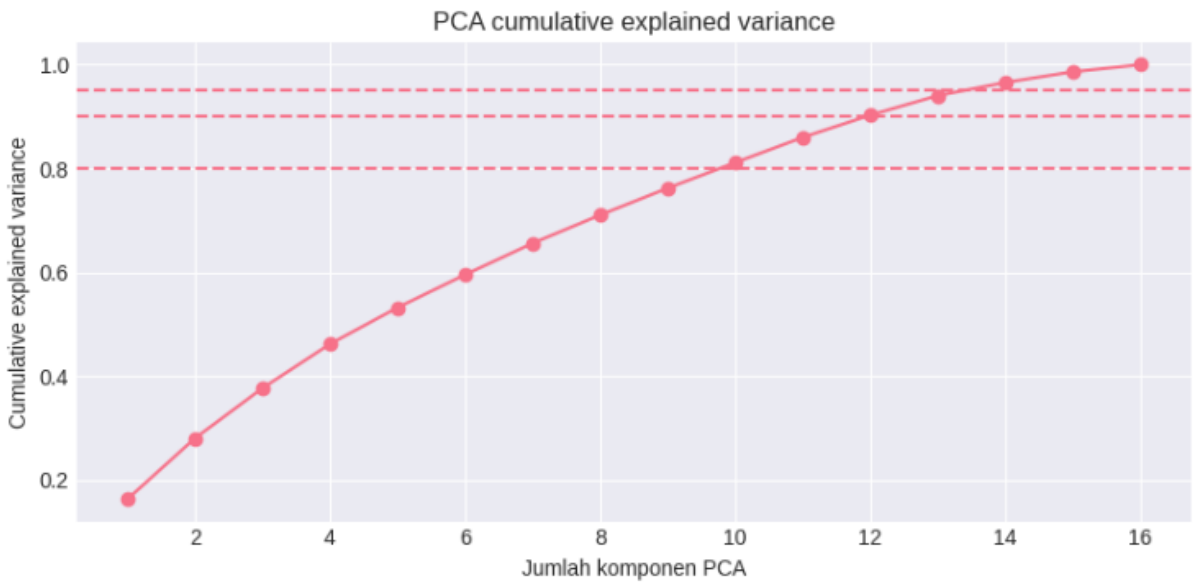

Gambar 1. Cumulative Explained Variance PCA

4.2 Hasil Clustering dengan Metode K-Means dan Evaluasi

-

Tahap berikutnya adalah melakukan proses **clustering** menggunakan algoritma **K-Means** pada data hasil reduksi PCA. Tujuan klasterisasi ini adalah untuk mengelompokkan individu berdasarkan kemiripan karakteristik yang berkaitan dengan faktor-faktor obesitas.

A. Penentuan Jumlah Cluster Optimal

Penentuan nilai **K (jumlah cluster)** dilakukan dengan dua pendekatan, yaitu **Elbow Method** dan **Silhouette Score**.

1. **Elbow Method**

   Grafik *Elbow Method* menunjukkan hubungan antara jumlah cluster (K) dengan nilai *Sum of Squared Errors (SSE)*. Dari hasil visualisasi, penurunan nilai SSE mulai melandai di sekitar **K = 7**, yang menandakan titik keseimbangan antara kompleksitas dan efisiensi model.

   Perkiraan K (Elbow Method): 7

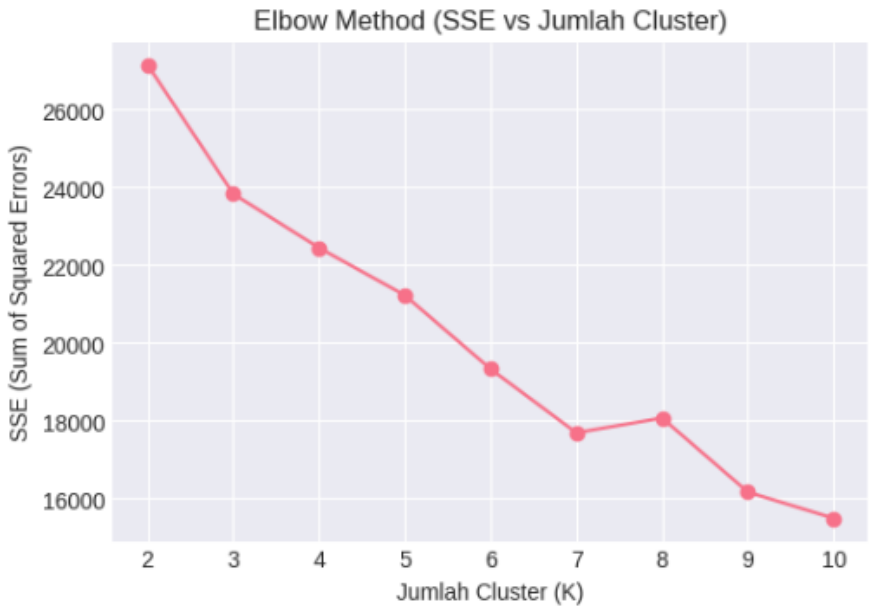

Gambar 2. Elbow Method (SSE)

2. **Silhouette Score**

   Evaluasi kualitas hasil clustering dilakukan menggunakan **Silhouette Score** untuk menentukan jumlah kluster yang optimal. Silhouette Score mengukur tingkat kemiripan suatu data terhadap kluster tempatnya berada dibandingkan dengan kluster lain, dengan nilai berkisar antara −1 hingga 1. Semakin mendekati nilai 1, maka kualitas pemisahan kluster semakin baik.

   Pengujian Silhouette Score dilakukan dengan mengevaluasi beberapa nilai jumlah kluster (K) dalam rentang tertentu. Berdasarkan hasil pengujian yang dilakukan, **nilai Silhouette tertinggi pada rentang jumlah kluster yang diuji diperoleh pada K = 10 dengan skor sebesar 0.1832**. Hasil ini menunjukkan bahwa jumlah kluster tersebut memberikan pemisahan kluster terbaik dibandingkan nilai K lainnya dalam rentang pengujian.

   Meskipun nilai Silhouette yang diperoleh tidak tergolong tinggi, hasil ini mengindikasikan bahwa struktur kluster masih dapat terbentuk, meskipun terdapat tumpang tindih antar

-

kluster. Oleh karena itu, nilai K = 10 dipilih sebagai jumlah kluster optimal untuk proses clustering menggunakan algoritma K-Means pada penelitian ini.

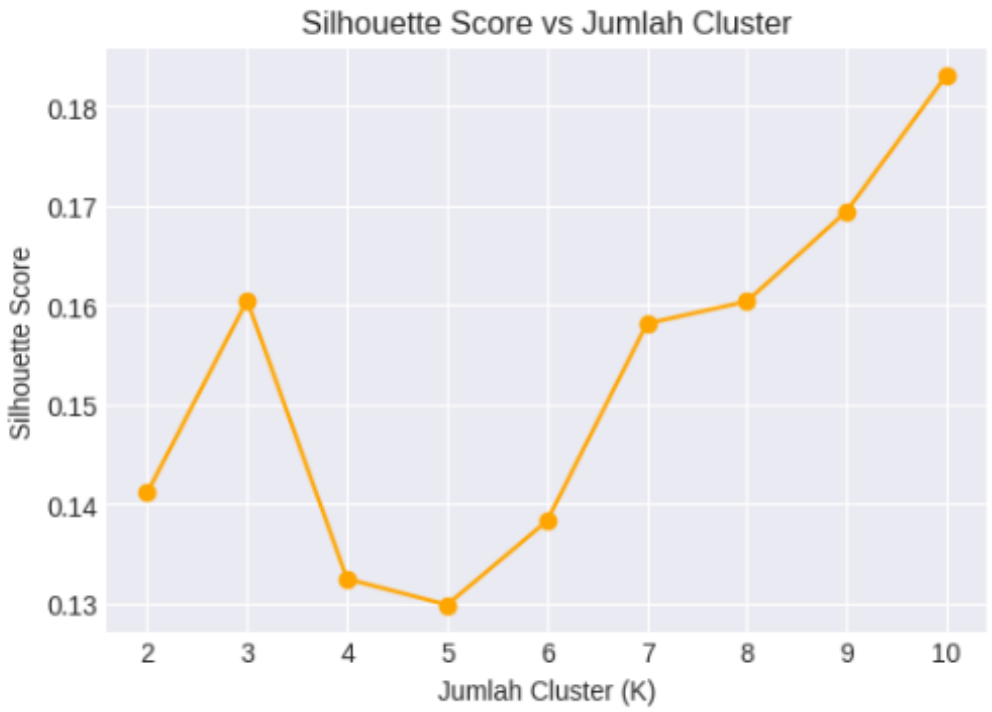

Gambar 3. Silhouette Score untuk Berbagai K

B. Evaluasi Kinerja Clustering

Setelah dilakukan klasterisasi menggunakan **K = 10**, diperoleh hasil evaluasi sebagai berikut:

Metrik Evaluasi	Nilai
Silhouette Score	0.1832
Davies-Bouldin Index	1.6765
Calinski-Harabasz Score	218.5072

Interpretasinya sebagai berikut:

- Silhouette Score (0.1832) menunjukkan bahwa antar cluster memiliki perbedaan yang cukup baik, meskipun belum sepenuhnya terpisah sempurna.
- Davies-Bouldin Index (1.6765) yang relatif kecil menunjukkan jarak antar cluster cukup berbeda dan tidak saling tumpang tindih secara signifikan.
- Calinski-Harabasz Score (218.5072) menunjukkan bahwa variasi antar cluster lebih besar dibandingkan variasi di dalam cluster, yang menandakan hasil klasterisasi cukup stabil.

C. Visualisasi Hasil Clustering

1. Visualisasi PCA 2DView

Gambar berikut memperlihatkan hasil klasterisasi pada ruang dua dimensi berdasarkan dua komponen utama PCA (PC1 dan PC2). Setiap warna mewakili satu cluster yang berbeda.

-

Terlihat bahwa penyebaran data cukup jelas dan membentuk kelompok-kelompok tertentu yang memiliki karakteristik serupa.

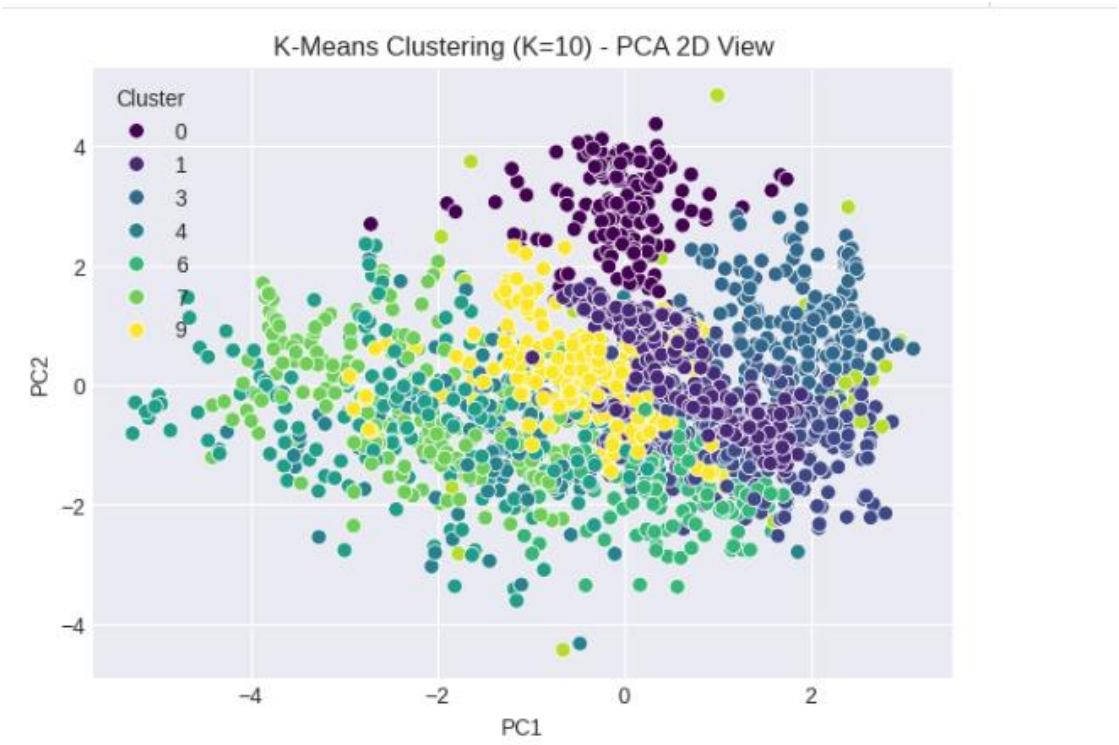

Gambar 4. Visualisasi PCA 2D (PC1 vs PC2) dengan K-Means (K=10)

3. Distribusi Jumlah Anggota Tiap Cluster

Gambar 5 menunjukkan distribusi jumlah anggota pada setiap klaster. Informasi ini membantu memahami keseimbangan ukuran klaster serta mengidentifikasi klaster minoritas yang berpotensi merepresentasikan pola khusus.

Gambar 5. Distribusi Jumlah Anggota Tiap Cluster (K=10)

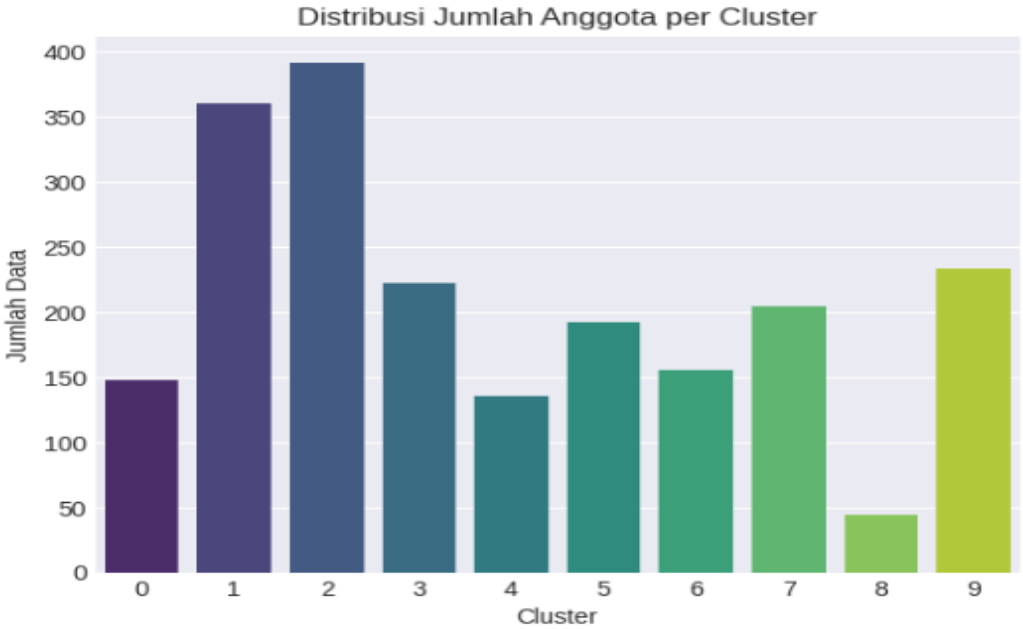

-

Cluster	Jumlah Data
0	148
1	360
2	392
3	222
4	135
5	192
6	156
7	205
8	44
9	233

Dari tabel tersebut terlihat bahwa **cluster 2** memiliki jumlah anggota terbanyak (392 data), sedangkan **cluster 8** memiliki jumlah anggota paling sedikit (44 data). Hal ini menunjukkan bahwa sebagian besar individu memiliki karakteristik yang serupa dalam kelompok tertentu, sementara cluster kecil menandakan adanya kelompok dengan karakteristik khusus yang jarang ditemui.

5. Kesimpulan

Berdasarkan analisis pada dataset obesitas, penerapan PCA mampu mereduksi dimensi data secara signifikan tanpa kehilangan informasi utama. Dengan ambang 90% cumulative explained variance, diperoleh 12 komponen utama yang menjelaskan 90,29% variasi pada 2.087 data setelah penghapusan duplikasi. Klasterisasi K-Means pada ruang PCA memilih K = 10 sebagai konfigurasi terbaik berdasarkan Silhouette Score, dengan hasil evaluasi internal Silhouette 0,1832, Davies-Bouldin 1,6765, dan Calinski-Harabasz 218,5072. Hasil ini menunjukkan bahwa struktur klaster terbentuk namun pemisahannya masih bersifat moderat. Secara keseluruhan, kombinasi PCA dan K-Means efektif sebagai pendekatan eksploratif untuk merangkum pola karakteristik obesitas dan dapat dikembangkan lebih lanjut dengan strategi encoding/klasterisasi yang lebih kaya.

6. Ucapan Terima Kasih

Kami selaku penulis mengucapkan terima kasih kepada dosen pengampu mata kuliah **Infrastruktur dan Platform untuk Sains Data** atas bimbingan, arahan, serta ilmu yang telah diberikan selama proses perkuliahan dan penyusunan tugas besar ini. Penulis juga menyampaikan apresiasi kepada seluruh pihak yang telah memberikan dukungan dan masukan sehingga laporan ini dapat diselesaikan dengan baik.

-

Laporan ini disusun oleh **Kelompok 7** yang terdiri dari **Muhammad Ilham Maulana**, **Izam Rosiawan**, dan **Muhammad Ade Sulistiansyah**. Penulis berharap laporan ini dapat memberikan manfaat serta menjadi sarana pembelajaran dalam memahami penerapan metode analisis data dan teknik unsupervised learning pada bidang sains data.

7. Referensi

[1] I. T. Jolliffe and J. Cadima, "Principal component analysis: a review and recent developments," Phil. Trans. R. Soc. A, vol. 374, 2016.

[2] I. T. Jolliffe, Principal Component Analysis, 2nd ed. Springer, 2002.

[3] J. A. Hartigan and M. A. Wong, "Algorithm AS 136: A K-means clustering algorithm," J. R. Stat. Soc. C, vol. 28, no. 1, pp. 100–108, 1979.

[4] D. Arthur and S. Vassilvitskii, "k-means++: The advantages of careful seeding," in Proc. SODA, 2007, pp. 1027–1035.

[5] P. J. Rousseeuw, "Silhouettes: a graphical aid to the interpretation and validation of cluster analysis," J. Comput. Appl. Math., vol. 20, pp. 53–65, 1987.

[6] D. L. Davies and D. W. Bouldin, "A cluster separation measure," IEEE Trans. Pattern Anal. Mach. Intell., vol. PAMI-1, no. 2, pp. 224–227, 1979.

[7] T. Calinski and J. Harabasz, "A dendrite method for cluster analysis," Commun. Stat., vol. 3, no. 1, pp. 1–27, 1974.

[8] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," J. Mach. Learn. Res., vol. 12, pp. 2825–2830, 2011.

[9] Scikit-learn Developers, "KMeans documentation," scikit-learn.org, accessed 2025.

[10] Scikit-learn Developers, "PCA documentation," scikit-learn.org, accessed 2025.

[11] P. Cortez and A. M. R. de Jesus, "Obesity levels based on eating habits and physical condition dataset," UCI Machine Learning Repository, 2019.

[12] World Health Organization, "Obesity and overweight," WHO fact sheet, accessed 2025.

[13] J. A. Costa et al., "Data mining in obesity research: a systematic review," Obesity Rev., 2021.

[14] A. M. De Jorge et al., "Machine learning approaches for obesity prediction: a review," IEEE Access, 2020.

[15] S. K. Jain, M. N. Murty, and P. J. Flynn, "Data clustering: a review," ACM Comput. Surv., vol. 31, no. 3, pp. 264–323, 1999.

[16] K. P. Murphy, Machine Learning: A Probabilistic Perspective. MIT Press, 2012.

-